

Eunhui Kim/KISTI

#### Tensors in Pytorch

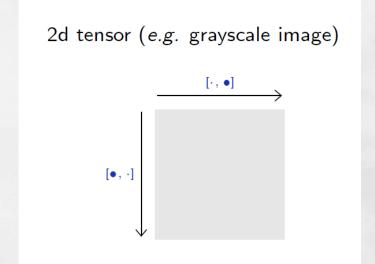
목차

- 1) Pytorch?
- 2) Tensor?
- 3) Tensor types & Devices
- 4) Tensor Scalar
- 5) Tensor vector/matrix operations
- 6) Tensor indexing, slicing
- 7) Tensor standard operations
- 8) Pytorch interface to image databases
- 9) BroadCasting
- 10) Tensor Internals
- 11) Pytorch 실습 on Google CoLab

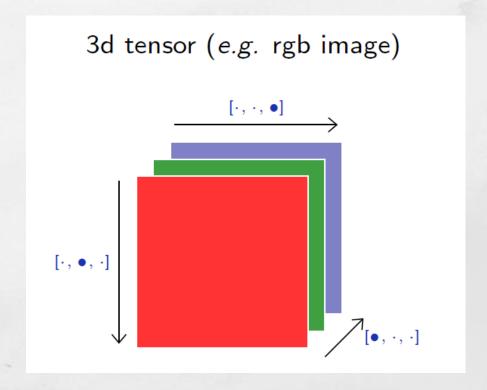
#### 1) Pytorch?

- PyTorch is Torch's THNN computational backend 를 기반으로 한 Python library 임.
- PyTorch 주요 특징:
  - CPU/GPU위에서 효율적인 tensor 연산들 지원,
  - 자동 미분 지원 (autograd),
  - optimizers,
  - data 입출력.
- 효율적인 tensor 연산들은 표준 linear algebra 연산들을 포함함. deep-learning 특화된 연산들 (convolution, pooling, etc.)을 또한 포함.
- PyTorch의 핵심이 되는 주요한 특징은 어떤 연산에 대해서도 미분을 지원하는 autograd 임!
- 이는 다음 수업시간에 다뤄짐

- tensor는 범용 matrix로 몇몇 이산 차원을 따라 색인된 산술 값을 갖는 table임
  - 0d tensor는 scalar(상수),
  - 1d tensor는 vector (e.g. a sound sample),
  - 2d tensor = matrix (e.g. a grayscale image),
  - 3d tensor는 동일 크기의 matrix로 구성된 vector (e.g. a multi-channel image),
  - 4d tensor는 동일 크기의 matrix로 구성된 matrix, 혹은 일련의 3d tensors sequence(e.g. a sequence of multi-channel images)
- Tensors는 처리할 신호를 encoding하는데 사용되지만, 모델의 내부 상태 및 매개 변수도 encoding합니다.
- 이 제한된 구조를 통해 데이터를 조작하면 CPU와 GPU를 최고 성능으로 사용할수 있습니다.
- 복합 데이터 구조는 더 다양한 데이터 유형을 나타낼 수 있습니다.

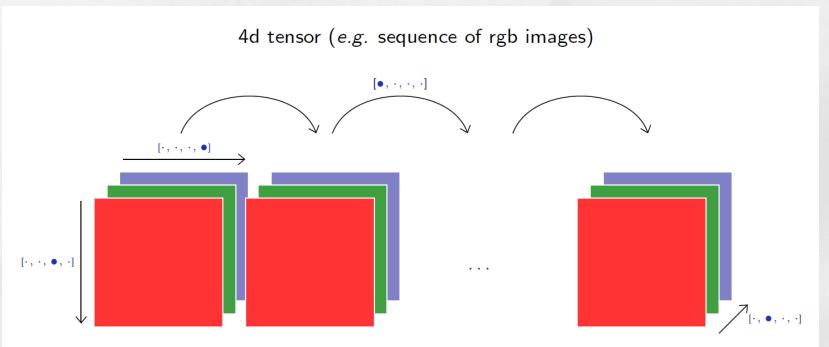












### 3) Tensor Types & Devices

- Tensor types
  - torch.float16, torch.float32, torch.float64,
  - torch.uint8,
  - torch.int8, torch.int16, torch.int32, torch.int64
- CPU의 메모리 혹은 GPU의 memory에 위치함
- 특정 장치의 메모리에 저장된 tensor 연산은 해당 장치에서 수행됨.
- 이는 Optimization 단원에서 다시 설명이 이뤄질 예정임.

### 3) Tensor types & device

```
In [2]: 1 import torch
          2 \times = torch.zeros(1, 3)
          3 x.dtype, x.device
Out[2]: (torch.float32, device(type='cpu'))
In [4]: 1 \times = x.long()
          2 x.dtype, x.device
Out[4]: (torch.int64, device(type='cpu'))
In [5]: 1 \times = \times.to('cuda')
          2 x.dtype, x.device
Out[5]: (torch.int64, device(type='cuda', index=0))
```



#### 4) Tensor Scalar

- In-place 연산들은 밑줄이 붙고, 0d tensor는 item()을 사용하여 Python scalar로 전환될 수 있음.
- 계수(coefficient)를 읽으면 0d tensor를 생성함.

```
>>> x = torch.tensor([[11., 12., 13.], [21., 22., 23.]])
>>> x[1, 2]
tensor(23.)
```

#### 5) Tensor Vector/Matrix Operations

■ PyTorch는 구성 요소 및 vector/matrix 연산을 위한 연산자를 제공함.

```
>>> x = torch.tensor([ 10., 20., 30.])
>>> y = torch.tensor([ 11., 21., 31.])
>>> x + y
tensor([ 21., 41., 61.])
>>> x * y
tensor([ 110., 420., 930.])
>>> x**2
tensor([ 100., 400., 900.])
>>> m = torch.tensor([[ 0., 0., 3. ],
                      [0., 2., 0.],
. . .
                      [1., 0., 0.]
>>> m.mv(x)
tensor([ 90., 40., 10.])
>>> m @ x
tensor([ 90., 40., 10.])
```

### 6) Tensor Indexing, Slicing

■ 그리고 numpy에서와 같이: symbol은 index값의 범위를 정의하고, tensor 를 슬라이스 함.

```
>>> import torch
>>> x = torch.empty(2, 4).random_(10)
>>> x
tensor([[8., 1., 1., 3.],
        [7., 0., 7., 5.]]
>>> x[0]
tensor([8., 1., 1., 3.])
>>> x[0, :]
tensor([8., 1., 1., 3.])
>>> x[:, 0]
tensor([8., 7.])
>>> x[:, 1:3] = -1
>>> x
tensor([[ 8., -1., -1., 3.],
        [7., -1., -1., 5.]
```

다음은 방대한 Tensor 연산 library의 몇 가지 예:

- Creation
  - torch.empty(\*size, ...)
  - torch.zeros(\*size, ...)
  - torch.full(size, value, ...)
  - torch.tensor(sequence, ...)
  - torch.eye(n, ...)
  - torch.from numpy(ndarray)
- Indexing, Slicing, Joining, Mutating torch.empty(\*size, ...)
  - torch.Tensor.view(\*size)
  - torch.cat(inputs, dimension=0)
  - torch.chunk(tensor, chunks, dim=0)[source]
  - torch.split(tensor, split size, dim=0)[source]
  - torch.index select(input, dim, index, out=None)
  - torch.t(input, out=None)
  - torch.transpose(input, dim0, dim1, out=None)

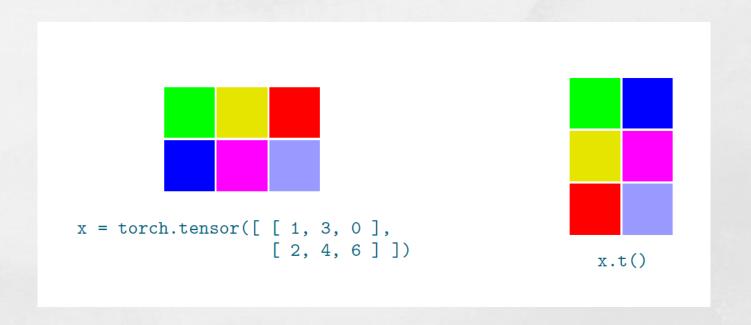


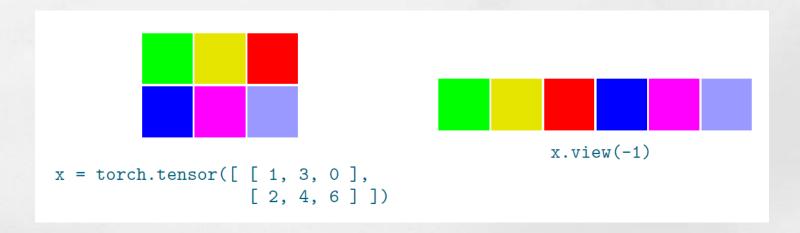
다음은 방대한 Tensor 연산 library의 몇 가지 예:

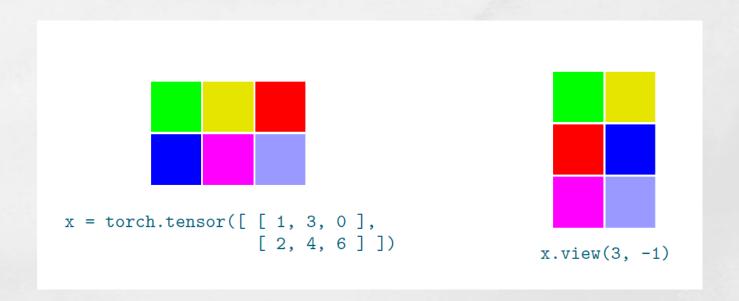
- Filling
  - Tensor.fill (value)
  - torch.bernoulli (proba)
  - torch.normal ([mu, [std]])
- Pointwise math
  - torch.abs(input, out=None)
  - torch.add()
  - torch.cos(input, out=None)
  - torch.sigmoid(input, out=None)
  - (+ many operators)
- Math reduction
  - torch.dist(input, other, p=2, out=None)
  - torch.mean()
  - torch.norm()
  - torch.std()
  - torch.sum()

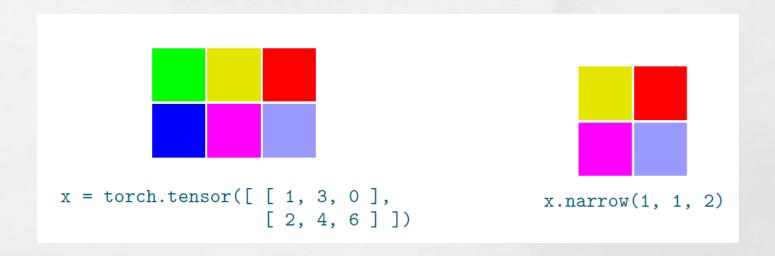
다음은 방대한 Tensor 연산 library의 몇 가지 예:

- BLAS and LAPACK Operations
  - torch.eig(a, eigenvectors=False, out=None)
  - torch.gels(B, A, out=None)
  - torch.lstsq(B, A, out=None)
  - torch.inverse(input, out=None)
  - torch.mm(mat1, mat2, out=None)
  - torch.mv(mat, vec, out=None)

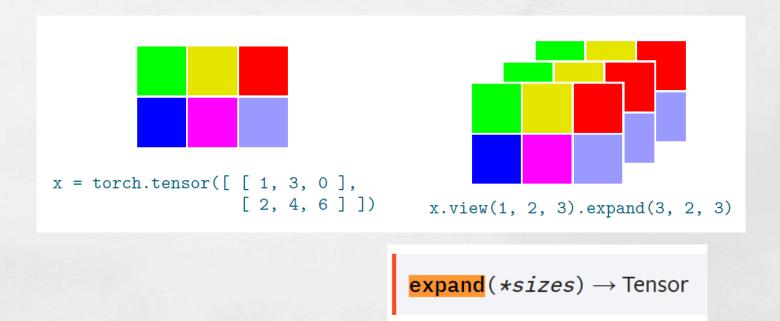




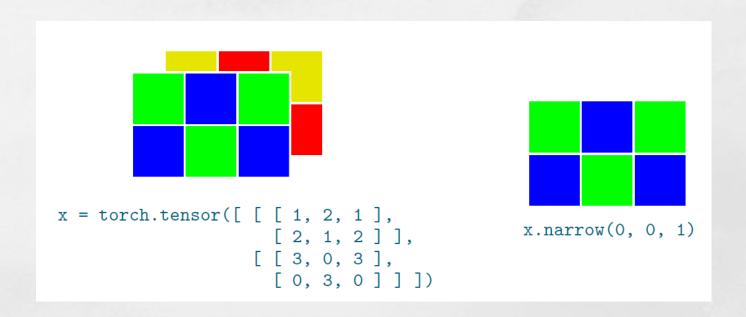


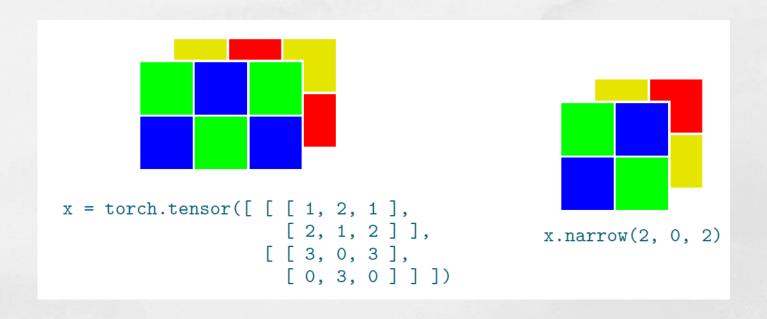


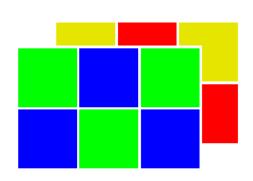
 $\texttt{torch.narrow}(\textit{input}, \textit{dim}, \textit{start}, \textit{length}) \rightarrow \texttt{Tensor}$ 



\*sizes (torch.Size or int...) - the desired expanded size



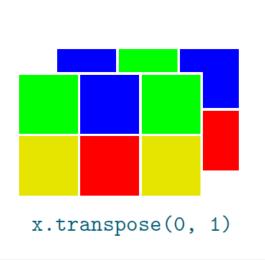




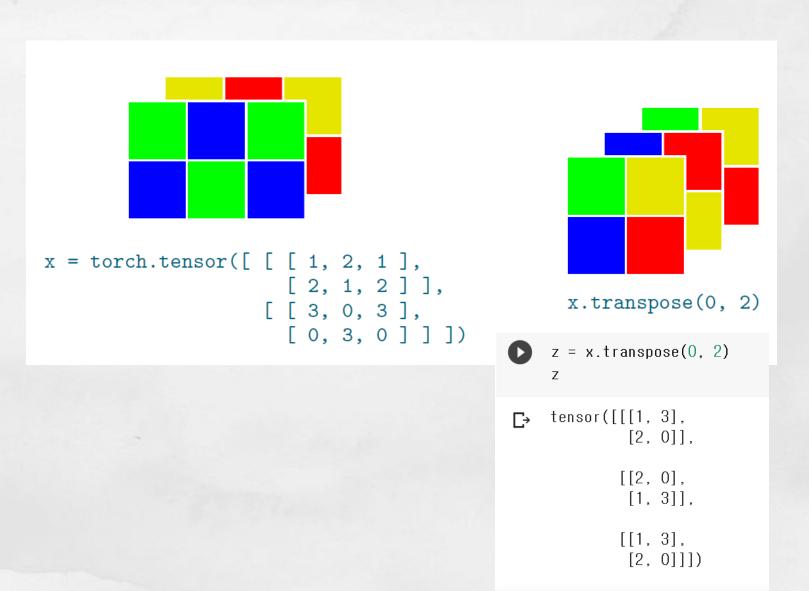
 $\texttt{torch.transpose}(\textit{input}, \textit{dim0}, \textit{dim1}) \rightarrow \texttt{Tensor}$ 

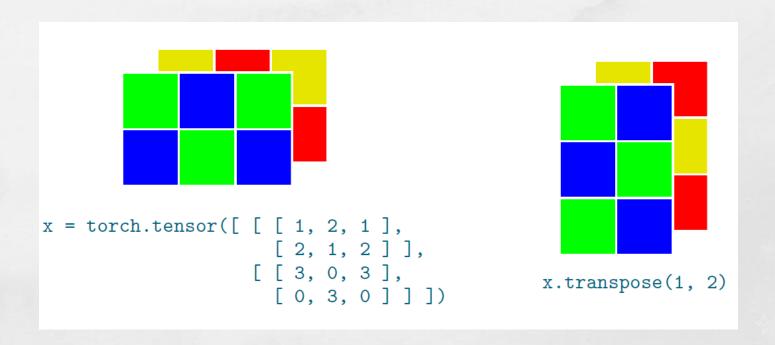
Returns a tensor that is a transposed version of input.

The given dimensions dim0 and dim1 are swapped.



[[2, 1, 2], [0, 3, 0]]])







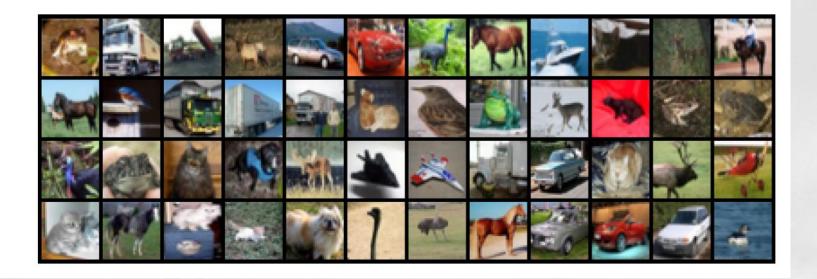
■ PyTorch 표준 image database에 대한 interface를 지원함.

```
import torch, torchvision
cifar = torchvision.datasets.CIFAR10('./cifar10/', train = True, download = True)
x = torch.from_numpy(cifar.train_data).transpose(1, 3).transpose(2, 3).float()
x = x / 255
print(x.type(), x.size(), x.min().item(), x.max().item())
prints
Files already downloaded and verified
torch.FloatTensor torch.Size([50000, 3, 32, 32]) 0.0 1.0
                                   [50,000,\cdot,\cdot,\cdot]
```



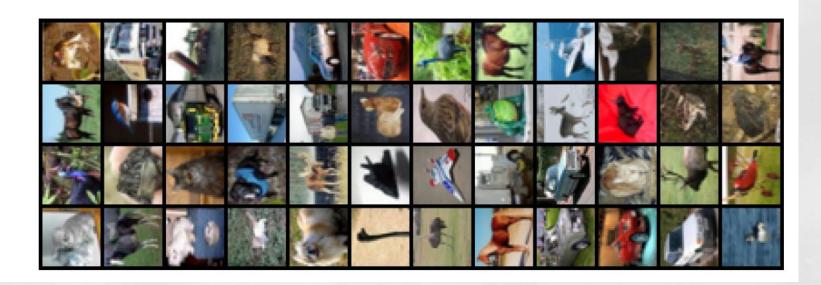
```
# Narrows to the first images, converts to float
x = x.narrow(0, 0, 48).float()

# Saves these samples as a single image
torchvision.utils.save_image(x, 'cifar-4x12.png', nrow = 12)
```





```
# Switches the row and column indexes
x.transpose_(2, 3)
torchvision.utils.save_image(x, 'cifar-4x12-rotated.png', nrow = 12)
```





```
# Kills the green and blue channels
x.narrow(1, 1, 2).fill_(0)
torchvision.utils.save_image(x, 'cifar-4x12-rotated-and-red.png', nrow = 12)
```



■ Broadcasting은 "직관적으로 합리적인" 작업을 수행해야 할 때, 계수를 복제하여 자동으로 자원을 확장하는 연산.

```
For instance:

>>> x = torch.empty(100, 4).normal_(2)
>>> x.mean(0)
tensor([2.0476, 2.0133, 1.9109, 1.8588])
>>> x -= x.mean(0) # This should not work!
>>> x.mean(0)
tensor([-4.0531e-08, -4.4703e-07, -1.3471e-07, 3.5763e-09])
```

- 정확하게, broadcasting은 다음과 같이 진행됨:
- 1. Tensor중 하나의 차원이 다른 tensor보다 적으면, 전면에 필요한 만큼 크기 1의 치수를 추가하여 모양을 변경함;

그 이후,

2. 모든 차원 불일치에 대해, 두 Tensor중 하나의 크기가 1이면 계수를 복제하여 축을 따라 확장함.

차원 중 한 차원의 tensor 크기가 일치하지 않고, 두 차원 중 1인 차원이 없는 경우는 Broadcasting 작업이 실패함.

```
A = torch.tensor([[1.], [2.], [3.], [4.]])
B = torch.tensor([[5., -5., 5., -5., 5.]])
C = A + B
```

1

2

3

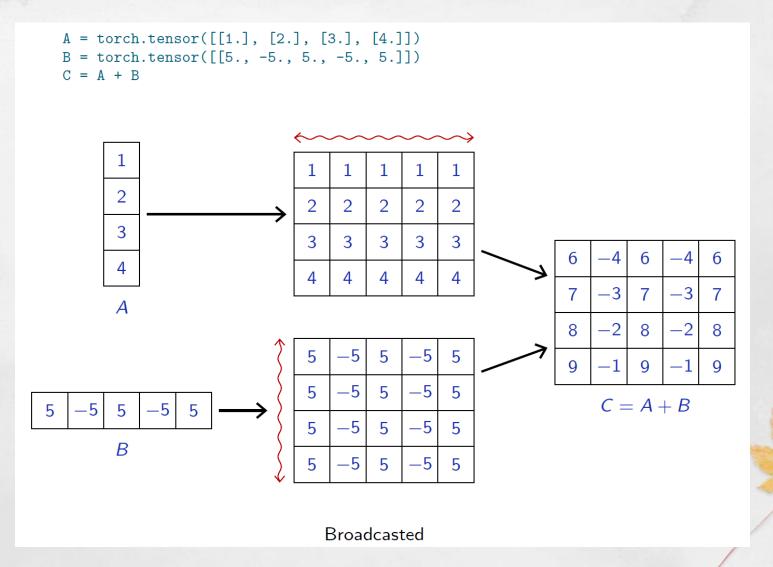
4

A



```
A = torch.tensor([[1.], [2.], [3.], [4.]])
B = torch.tensor([[5., -5., 5., -5., 5.]])
C = A + B
                            4
                                4
                                    4
                               -5
                                        -5
                                       -5
 -5
                                        -5
```

Broadcasted



■ Tensor는 저 수준 1-d vector로 일련의 저장소로 간주할 수 있음.

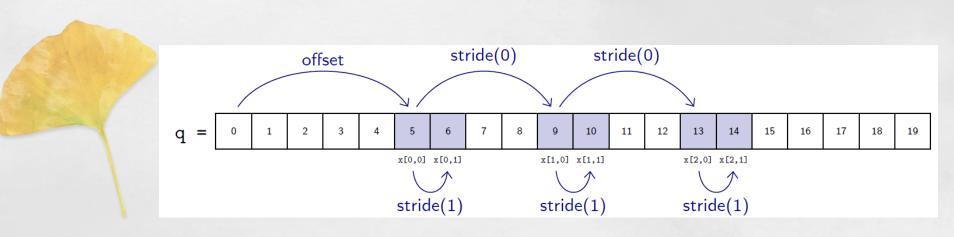
```
>>> x = torch.zeros(2, 4)
>>> x.storage()
0.0
0.0
0.0
0.0
0.0
0.0
0.0
0.0
[torch.FloatStorage of size 8]
>>> q = x.storage()
>>> q[4] = 1.0
>>> x
tensor([[ 0., 0., 0., 0.],
        [ 1., 0., 0., 0.]])
```

■ Multiple tensors는 같은 저장소를 공유 가능함. view(), expand() or transpose()와 같은 연산을 사용할 경우 공유 가능.

```
>>> y = x.view(2, 2, 2)
>>> y
tensor([[[ 0., 0.],
        [0., 0.]],
       [[1., 0.],
       [0., 0.]]
>>> y[1, 1, 0] = 7.0
>>> x
tensor([[ 0., 0., 0., 0.],
      [1., 0., 7., 0.]
>>> y.narrow(0, 1, 1).fill_(3.0)
tensor([[[ 3., 3.],
       [3., 3.]])
>>> x
tensor([[ 0., 0., 0., 0.],
       [3., 3., 3., 3.]
```



- Tensor의 첫 번째 계수는 storage()의 storage\_offset()에 있는 계수임.
- index k 를 1씩 증가시키려면, storage에서 stride(k) 요소로 이동해야 함.



■ 동일한 storage에 대해 명시적으로 서로 다른 "view"를 생성 가능함

■ 이는 특히 transpositions 과broadcasting이 구현되는 방법임.

• 아래 예시는 (아마도 놀라운) error를 설명함

```
>>> x = torch.empty(100, 100)
>>> x.stride()
(100, 1)
>>> y = x.t()
>>> y.stride()
(1, 100)
>>> y.view(-1)
Traceback (most recent call last):
   File "<stdin>", line 1, in <module>
RuntimeError: invalid argument 2: view size is not compatible with input tensor's size and stride (at least one dimension spans across two contiguous subspaces).
```

- x.t() 는 x's storage를 공유하고 1d로 flattened될 수 없음.
- 이것은 Tensor의 연속 버전을 반환하는 contiguous()로 고칠 수 있으며, 필요한 경우 복사본을 만들거나 view()와 contiguous()를 결합하는 reshape()으로 해결 가능함.

#### Linear Regression

지점들로 구성된 dataset에 대해, 이 dataset을 표현하는 "best line"을 찾을 수 있음.  $(x_n, y_n) \in \mathbb{R} \times \mathbb{R}, \ n = 1, ..., N$ ,

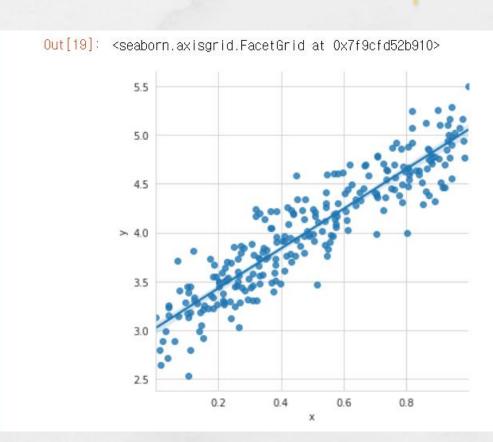
예로) 지점들을 통과하는 선을 통해 mean squared error를 최소화 할 수 있음.

$$f(x; a, b) = ax + b$$

이 모델은 새로운 입력 x에 대해 관련된 f(x;a,b)를 계산하여 y예측이 가능함.

$$\underset{a,b}{\operatorname{argmin}} \frac{1}{N} \sum_{n=1}^{N} \left( \underbrace{ax_n + b}_{f(x_n;a,b)} - y_n \right)^2.$$

```
In [19]:
           1 | import numpy as np
           2 import matplotlib.pyplot as plt
           3 from matplotlib.animation import FuncAnimation
           4 import seaborn as sns
           5 import pandas as pd
           6 %matplotlib inline
           8 sns.set style(style = 'whitegrid')
             plt.rcParams["patch.force edgecolor"] = True
          11 m = 2 \# s/ope
          12 c = 3 # interceptm = 2 # slope
          13 c = 3 # intercept
          14
          15 \mid x = np.random.rand(256)
          17 noise = np.random.randn(256) / 4
          19 y = x * m + c + noise
         20
         21 df = pd.DataFrame()
          22 | df['x'] = x
         23 df['v'] = v
          25 sns.Implot(x = 'x', y = 'y', data = df)
```



```
import torch
    import torch.nn as nn
    from torch autograd import Variable
   | \times \text{train} = \times.\text{reshape}(-1, 1).\text{astype}('float32')
   y train = y.reshape(-1, 1).astype('float32')
    class LinearRegressionModel(nn.Module):
       def __init__(self, input_dim, output_dim):
          super(LinearRegressionModel, self). init ()
          self.linear = nn.Linear(input dim, output dim)
       def forward(self, x):
14
          out = self.linear(x)
          return out
17 | input dim = x train.shape[1]
   output dim = v train.shape[1]
   print('input d. output d = {}. {}'.format(input dim. output dim)
   #mode/ settina
   model = LinearRegressionModel(input_dim, output_dim)
   criterion = nn.MSELoss()
24
25 #optimizer setting
26 | I rate = 0.01
27 optimizer = torch.optim.SGD(model.parameters(), Ir = I_rate)
   epochs = 2000
```

```
30 #training the model
31 for epoch in range(epochs):
        epoch += 1
34
        inputs = Variable(torch.from_numpy(x_train))
        labels = Variable(torch.from_numpy(y_train))
        #clear grads
       optimizer.zero_grad()
40
        #forward to get predicted values
        outputs = model.forward(inputs)
41
42
        loss = criterion(outputs, labels)
43
        loss.backward() #back props
       optimizer.step() #update the parameters
44
       #print('epoch {}, loss {}'.format(epoch, loss,data))
   predicted = model.forward(Variable(torch.from_numpy(x_train))).data.numpy()
   plt.plot(x_train, y_train, 'go', label='from data', alpha = .5)
   plt.plot(x train, predicted, label='prediction', alpha = .5)
   plt.legend()
   plt.show()
   print(model.state_dict())
54
```

```
predicted = model.forward(Variable(torch.from_numpy(x_train))).data.numpy()

plt.plot(x_train, y_train, 'go', label='from data', alpha = .5)

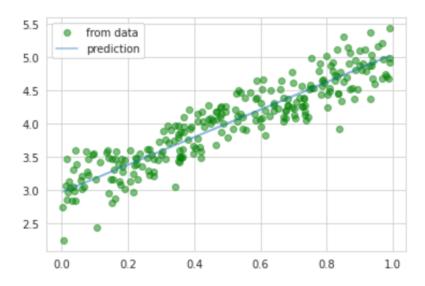
plt.plot(x_train, predicted, label='prediction', alpha = .5)

plt.legend()

plt.show()

print(model.state_dict())
```

```
input_d, output_d = 1, 1
```



OrderedDict([('linear.weight', tensor([[2.0803]])), ('linear.bias', tensor([2.9609]))])

