

Eunhui Kim/KISTI

Modules in Pytorch

목차

- 1) torch.nn.Module, torch.nn.functional
- 2) torch.nn.functional.relu
- 3) torch.nn.Linear
- 4) torch.nn.MSELoss
- 5) PyTorch- Batch Processing
- 6) PyTorch Convolutional Neural Network
- 7) PyTorch Padding, Stride
- 8) Pytorch Dilated Convolution
- 9) Creating a Module
- 10) 실습 on CoLab

1) torch.nn.Module, torch.nn.functional

- torch.nn.functional 의 요소는 제공된 인수만으로 결과를 계산하는 autograd 호 한 함수로, 보통 F로 import 됨. (e. g. import torch.nn.functional as F)
- torch.nn.Module 의 Subclass들은 losses 와 <u>network components</u>임.
- 후자(network components)는 훈련 중에 최적화 할 매개 변수를 포함함.

■ 매개변수는 requires_grad 가 True인 torch.nn.Parameter 유형이며, 다양한 유틸리티 함수, 특히 torch.nn.Module.parameters(),의 모델 파라미터로 알려짐.

1) torch.nn.Module, torch.nn.functional

! torch.nn 함수와 모듈은 첫 번째 차원이 이를 인덱싱 하는 tensor에 저장된 입력 배치(batches of inputs)를 처리하고, 동일한 추가 차원을 갖는 해당 tensor를 생성함.

E.g. a fully connected layer $R^C \to R^D$ 는 크기 $N \times C$ 의 입력 tensor를 예상하고, $N \times D$ 크기의 tensor를 계산함. 여기서 N 은 샘플의 수이며 호출마다 다를 수 있음.

2) torch.nn.functional.relu

torch.nn.functional.relu(input, inplace=False)

모드 크기의 tensor를 입력으로 취할 수 있으며, 입력 tensor 각 값에 ReLU를 적용하여 동일한 크기의 결과 tensor를 생성함.

inplace 는 연산 시 인수자체를 수정해야 하는지의 여부를 나타냄. 이는 처리 시 memory footprint를 줄이는 장점을 지님.

3) torch.nn.Linear

모듈

torch.nn.Linear(in_features, out_features, bias=True)



은 a $R^C \to R^D$ 완전 연결 계층을 구현함. $N \times C$ 의 입력 tensor를 취해서 크기 $N \times D$ 의 출력 tensor를 생성함.

```
>>> f = nn.Linear(in_features = 10, out_features = 4)
>>> for n, p in f.named_parameters(): print(n, p.size())
...
weight torch.Size([4, 10])
bias torch.Size([4])
>>> x = torch.empty(523, 10).normal_()
>>> y = f(x)
>>> y.size()
torch.Size([523, 4])
```

! 생성 시 weights와 biases는 자동으로 생성됨. 초기화 관련하여서 optimization에서 다시 다룰 예정임.

4) torch.nn.MSELoss()

모듈

torch.nn.MSELoss()

은 Mean Square Error loss를 구현함: tensor의 **총 성분** 수로 나는 성분 별 제곱 차이의 합

```
>>> f = torch.nn.MSELoss()
>>> x = torch.tensor([[ 3. ]])
>>> y = torch.tensor([[ 0. ]])
>>> f(x, y)
tensor(9.)
>>> x = torch.tensor([[ 3., 0., 0., 0. ]])
>>> y = torch.tensor([[ 0., 0., 0., 0. ]])
>>> f(x, y)
tensor(2.2500)
```

보통 loss의 첫 번째 매개변수는 input이고, 두 번째 매개변수는 target임. target. 이 두 수량은 일부 손실에 대해 서로 다른 차원이거나 서로 다른 type일 수 있음. (e.g. for classification).



5) PyTorch- Batch Processing

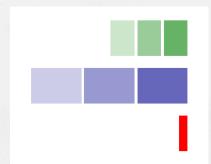
- Functions and modules from torch.nn 의 함수 및 모듈은 샘플들을 batches로 처리함. 이는 이를 유도하는 <u>계산 속도 향상</u>을 위함.
- 샘플의 모듈을 계산하기 위해서는 모듈의 매개변수와 샘플이 모두 <u>cache</u> <u>memory</u>로 먼저 복사되어야 함. 그런데 이 cache memory는 <u>빠르지만 작음</u>.
- 합리적인 크기의 모델에 대해 매개 변수의 일부만 cache에 유지가 가능함. 따라서 매개변수가 사용될 때 마다 모듈의 매개 변수가 cache에 복사되어야함.
- 이러한 메모리 전달은 연산 그 자체보다 더 느릴 수 있음.
- 이것이 batch processing의 주된 이유이며, cache에 대한 매개 변수 사본 수를 batch당 module당 하나씩으로 줄임.
- 또한 매우 느린 Python loops 사용을 줄임.

5) PyTorch- Batch Processing

■ 세 module로 구성된 model을 예시로 들어보면,

 $f = f_3 \circ f_2 \circ f_1$ 계산 되어야 하는 함수는 $f(x_1), f(x_2), f(x_3)$ 이 됨.



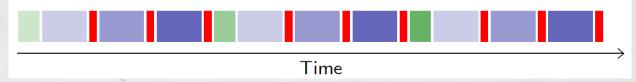


 x_n 을 cache memory로 복사

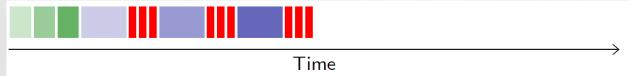
 f_d 의 매개별수를 cache memory로 복사

 $f_d(x_1)$ 를 계산

■ 샘플들을 하나씩 처리하는 경우:



Batch processing:



5) PyTorch- Batch Processing

```
import time
   def timing(x, w, batch = False, nb = 101):
       t = torch.zeros(nb)
        for u in range(0, t.size(0)):
            t0 = time.perf_counter()
            if batch:
                y = x.mm(w.t())
                y = torch.empty(x.size(0), w.size(0))
                for k in range(y.size(0)):
11
12
                    \vee[k] = w.m\vee(\times[k])
            y.is_cuda and torch.cuda.synchronize()
            t[u] = time.perf counter() - t0
14
15
        return t.median().item()
   \times = torch.empty(2500, 1000).normal_()
   w = torch.empty(1500, 1000).normal_()
   print('Batch-processing speed-up on CPU %.1f' %
          (timing(x, w, batch = False)/timing(x, w, batch = True)))
21
23 \times = \times.to('cuda')
   w = w.to('cuda')
   print('Batch-processing speed-up on GPU %.1f' %
          (timing(x, w, batch = False)/timing(x, w, batch = True)))
```



Batch-processing speed-up on CPU 16.4 Batch-processing speed-up on GPU 102.8

5) PyTorch-Batch Processing

■ 공식적으로 이전에 살펴본 완전연결계층(fully connected layer)에 대해 몇 가지 표현을 다시 검토해 보면,

$$\forall l, n, w^{(l)} \in R^{d_l \times d_{l-1}}, x_n^{(l-1)} \in R^{d_{l-1}}, s_n^{(l)} = w^{(l)} \times x_n^{(l-1)}$$

■ 이제부터는 행 벡터를 사용하여 일련의 샘플을 <u>첫 번째 인덱스가 샘플의 인덱스</u> 인 2D 배열로 나타낼 수 있음.

$$x = \begin{pmatrix} x_{1,1} & \dots & x_{1,D} \\ \vdots & \ddots & \vdots \\ x_{N,1} & \dots & x_{N,D} \end{pmatrix} = \begin{pmatrix} (x_1)^T \\ \vdots \\ (x_N)^T \end{pmatrix},$$

이는 $R^{N \times D}$ 의 요소임.

5) PyTorch-Batch Processing

■ 모든 샘플 행 벡터를 만들고 선형 연산자(linear operator)를 적용하려면,

$$\forall n, s_n^{(l)} = \left(w^{(l)} \left(x_n^{(l-1)}\right)^T\right)^T = x_n^{(l-1)} \left(w^{(l)}\right)^T$$

■ 전체 batch에 대해 tensorial 표현을 제공함

$$s^{(l)} = x_n^{(l-1)} (w^{(l)})^T$$

And in torch/nn/functional.py

```
In [16]:

def linear(input, weight, bias=None):
    if input.dim() == 2 and bias is not None:
        #fused op is marginally faster
        return torch.addmm(bias, input, weight.t())

output = input.matmul(weight.t())

if bias is not None:
    output += bias
    return output
```

5) PyTorch-Batch Processing

■ 유사하게 선형 계층의 backward pass는다음과 같이 표현됨

$$\left[\frac{\partial L}{\partial w^{(l)}}\right] = \left[\frac{\partial L}{\partial x^{(l)}}\right]^T x^{(l-1)}$$



그리고

$$\left[\frac{\partial L}{\partial x^{(l)}}\right] = \left[\frac{\partial L}{\partial x^{(l+1)}}\right]^T w^{(l+1)}$$

■ 정상적인 "구조화되지 않은"벡터로 취급되는 경우 사운드 샘플 또는 이미지와 같은 대형 신호에는 다루기 힘든 크기의 모델이 필요하게 됨.



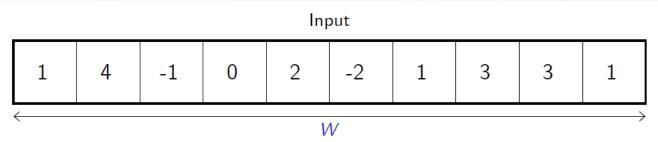
■ 예를 들어 256x256 RGB 이미지를 입력으로 사용하고 동일한 크기의 이미지를 생성하는 선형 레이어에는

$$(256 \times 256 \times 3)^2 \approx 3.87e + 10$$

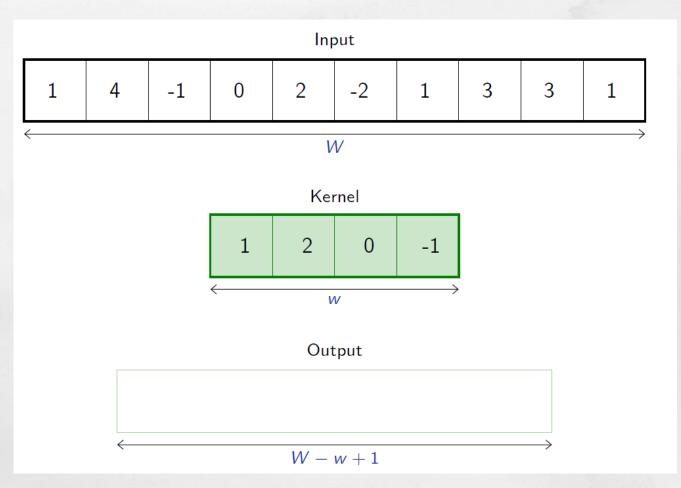
해당 메모리 foot print(≈ 150Gb!) 및 초과 용량과 함께 매개 변수가 필요함.



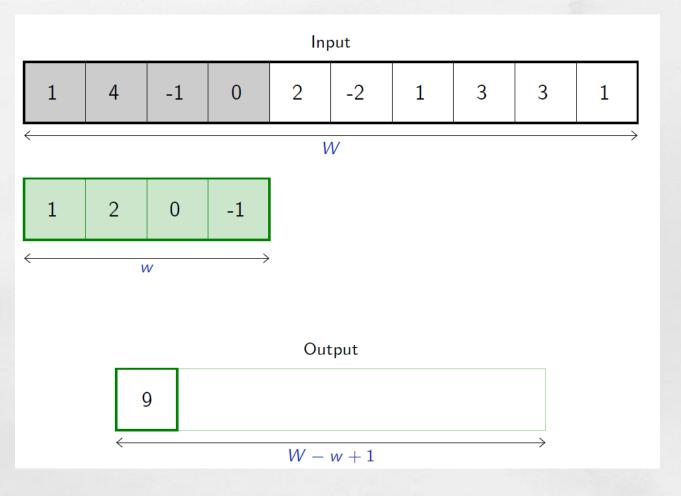
- 더욱이,이 요구 사항은 그러한 큰 신호가 "invariance in translation "을 갖는다는 직관과 일치하지 않음. 특정 위치에서 의미 있는 표현은 모든 곳에서 사용될 수 있어야 함.
- A convolution layer는 이 아이디어를 구현한 것임. 즉, 동일한 선형 변환을 로 컬, 모든 곳에 적용하고 신호 구조를 보존함.



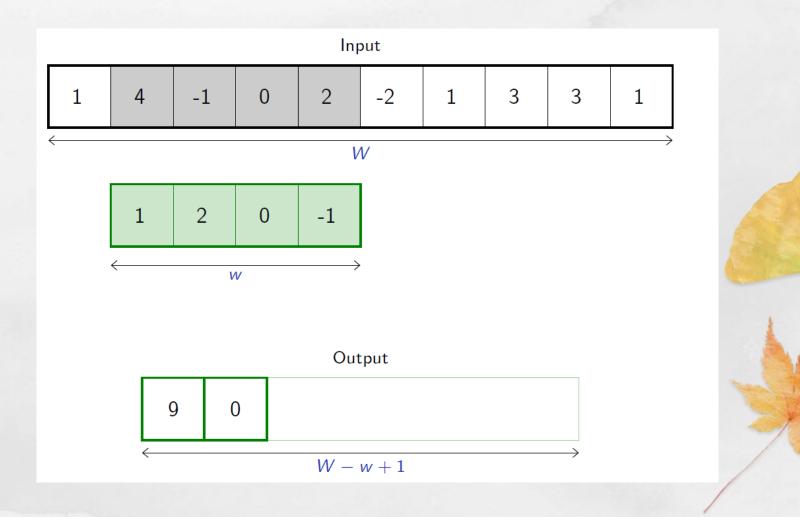


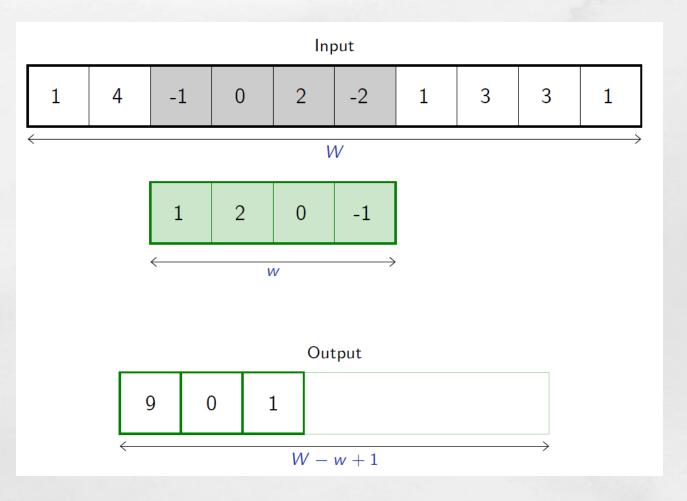




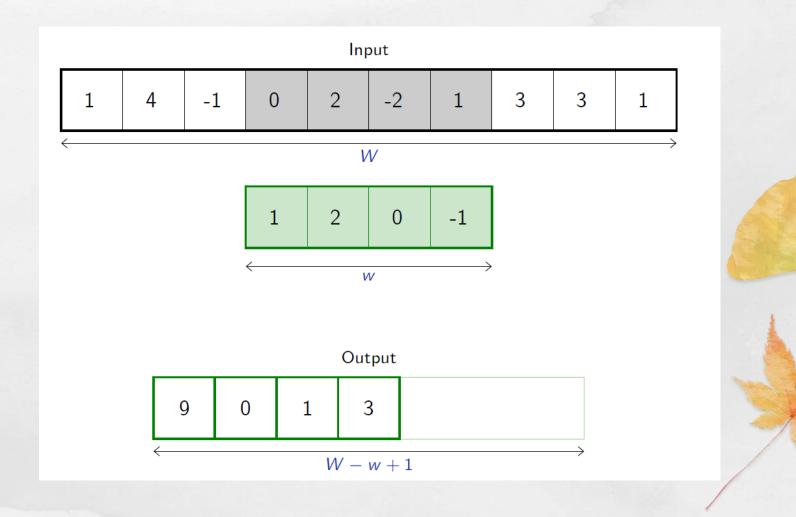


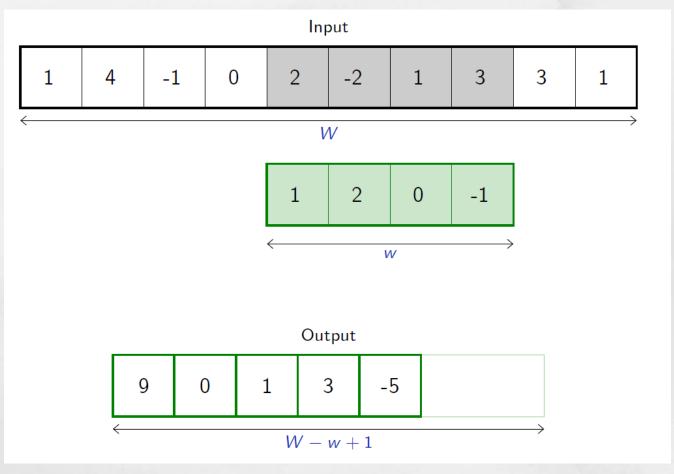




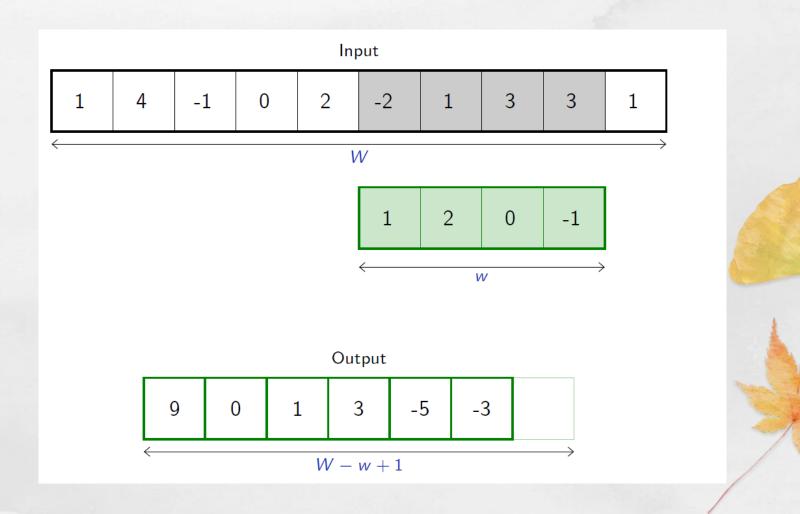


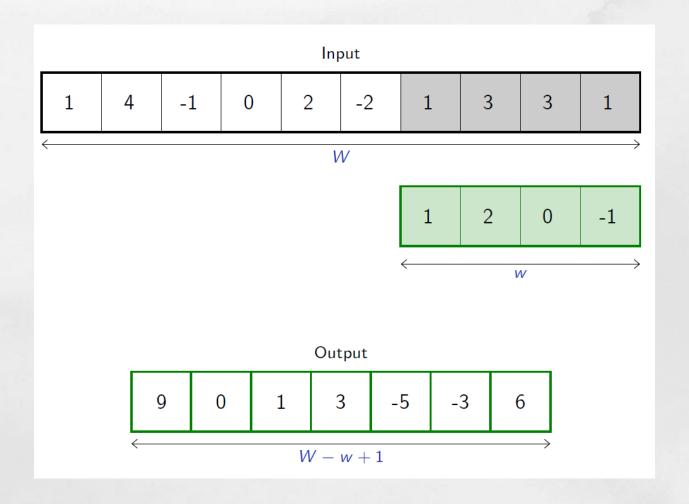




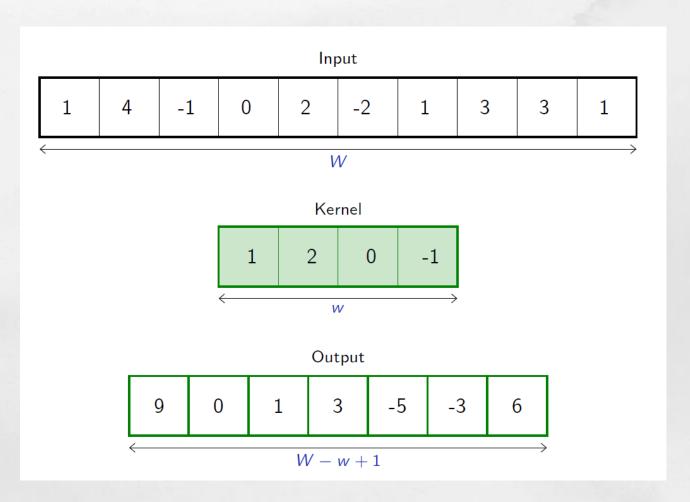














■ 공식적으로, 1d에서, 입력 값이 다음과 같이 주어질 때,

$$x = (x_1, \cdots, x_W)$$

■ 그리고 너비 w의 "convolution kernel" (혹은 "filter") 가 주어진 경우,

$$u=(u_1,\cdots,u_W)$$

• convolution 연산 x * u 은 크기 W - w + 1 vector이다.

$$(x \circledast u)_i = \sum_{j=1}^w x_{i-1+j} u_j$$
$$= (x_i, \dots, x_{i+w-1}) \cdot u$$

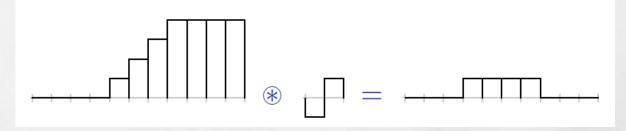
예를 들어,

$$(1,2,3,4) \circledast (3,2) = (3+4,6+6,9+8) = (7,12,17).$$

! 이것은 커널과 신호가 모두 인덱스 순서로 증가하기 때문에 일반적인 convolution과 다름.

■ Convolution은 특히 미분 연산자를 구현할 수 있음. e.g.

$$(0,0,0,0,1,2,3,4,4,4,4) \otimes (-1,1) = (0,0,0,1,1,1,1,0,0,0).$$

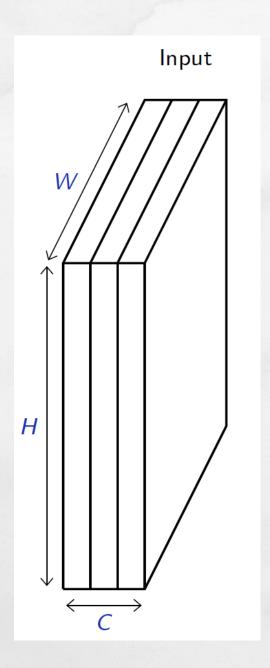


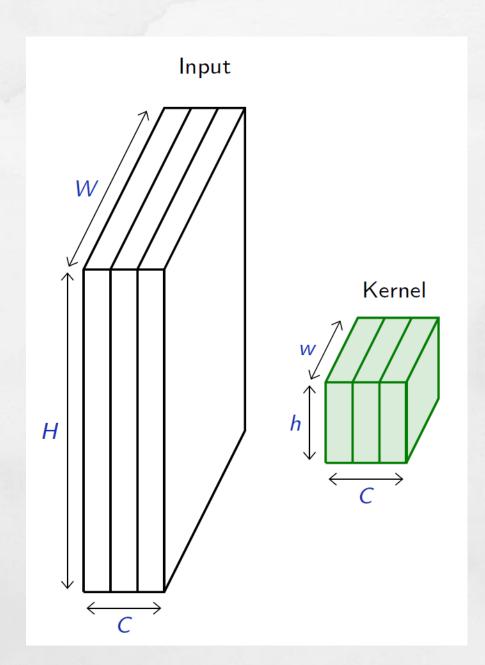
■ 혹은 "template matcher", e.g.



■ 두 연산 예시 모두 실제로 "invariant by translation "하다.

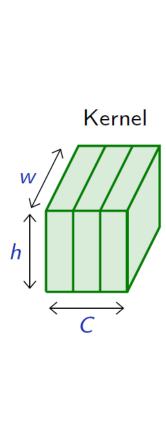
- 특정 application에 따라 복잡해질 수 있지만, 일반적으로 다차원 입력으로 일반화 될 수 있음.
- "convolutional networks" 의 가장 일반적인 형태는 3D 텐서를 입력 (즉, 다중 채널 2D 신호)으로 처리하여 2D 텐서를 출력함. kernel은 행과 열을 가로 질러 채널간에 스와이프되지 않음.
- 이러한 경우, 만일 입력 tensor가 크기 $C \times H \times W$ 이고 kernel이 $C \times h \times w$ 인 경우, 출력은 크기 $(H h + 1) \times (W w + 1)$ 임.
- ! C채널이 있더라도 "2d 신호라" 함, feature index에 구조가 없는 2D 위치에 의해 index되는 feature vector이기 때문임.
- 표준 convolution 계층에서 , D 개의 convolutions은 결합되어 $D \times (H h + 1) \times (W W + 1)$ 개의 출력을 생성함.

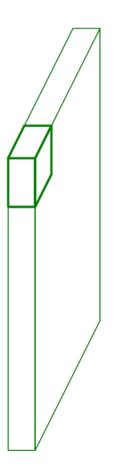




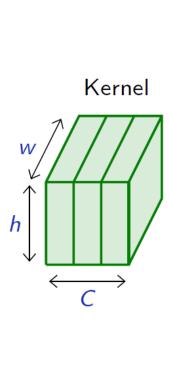


Input W H



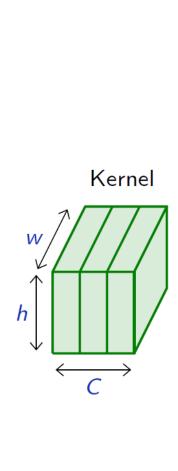


Input W Н



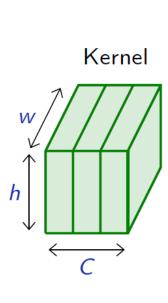


Input W Н



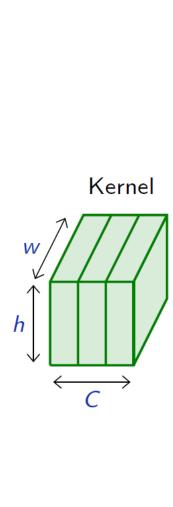


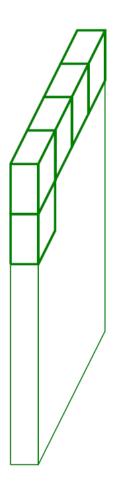
Input Н



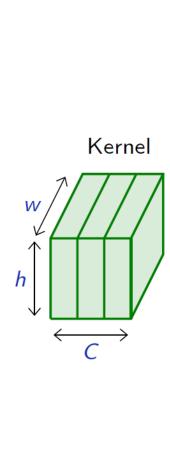


Input Н

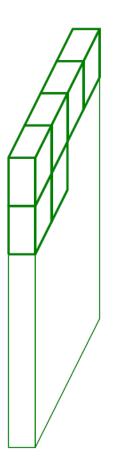


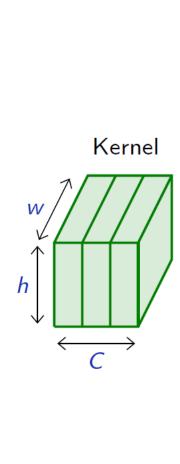


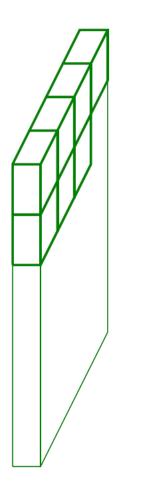
Input W Н

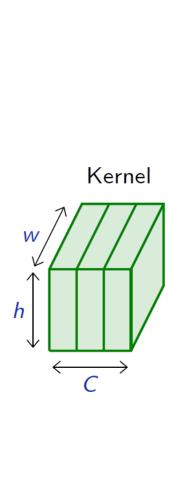


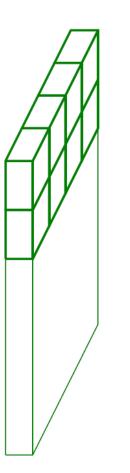
Output

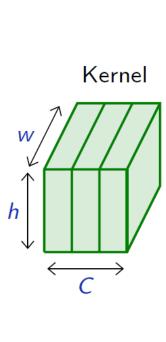


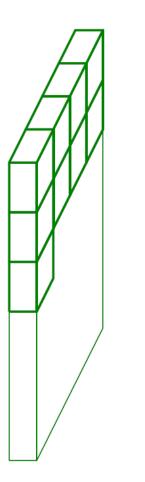


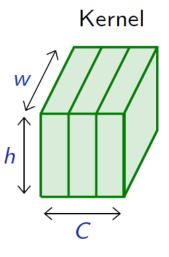


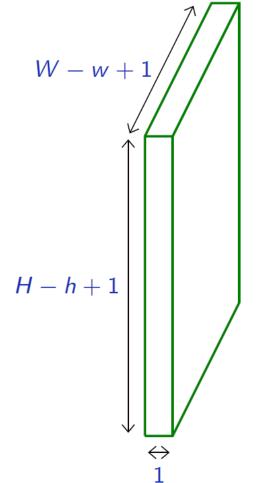


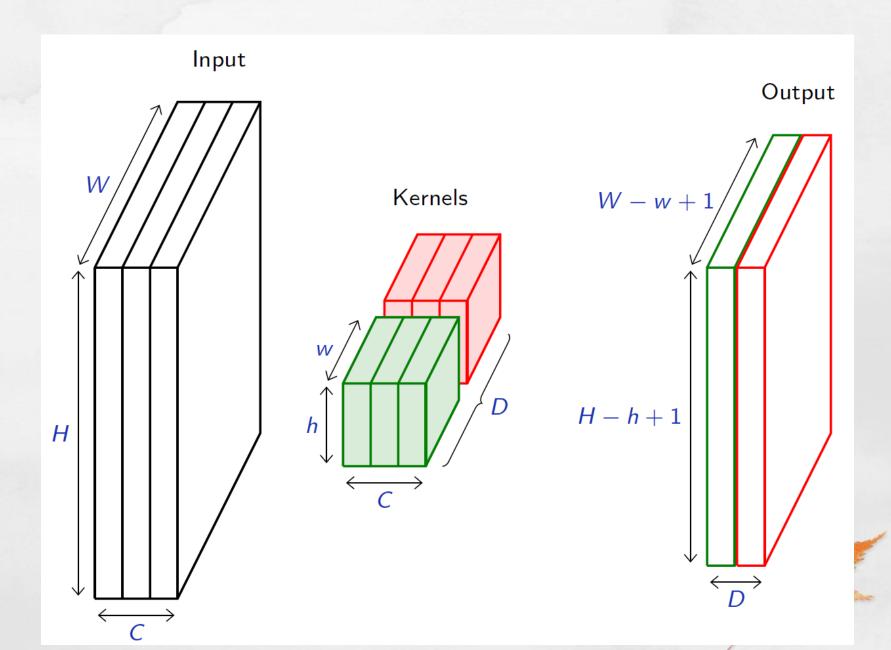












- convolution은 신호 지원 구조를 유지함.
- 1d 신호는 1d 신호로 전환되고, 2d신호는 2d신호로 전환됨. 입력 신호의 이웃한 부분들은 출력 신호의 이웃한 부분들에 영향을 미치게 됨.
- 채널 인덱스가 일련의 회색조 비디오 프레임에서 시간과 같은 metric 의미인 경우, 3d convolution 을 사용할 수 있음. 그런 것이 아니라면, 채널을 스 와이프하는 것은 의미가 없음.



- 보통 <u>convolution layer</u>에서 생성한 채널 중 하나를 activation map으로 참조함
- 입력의 부분 영역들이 activation map의 receptive field로서 출력 요소에 영향을 미침.
- convolutional networks의 context에서 표준 linear계층은 완전연결계층(a fully connected layer)이라 부르는데 입력이 모두 출력에 직접 영향을 미치기 때문임.

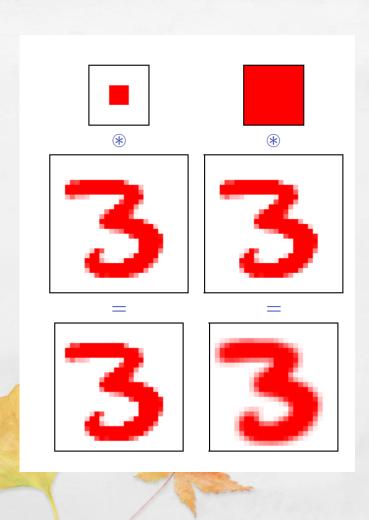


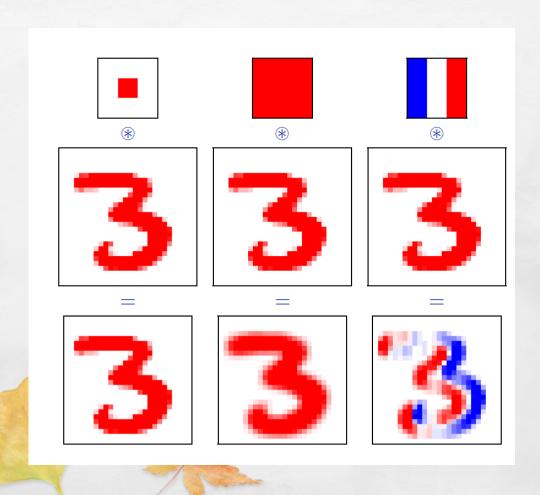
torch.nn.functional.conv2d(input, weight, bias=None, stride=1, padding=0, dilation=1, groups=1)

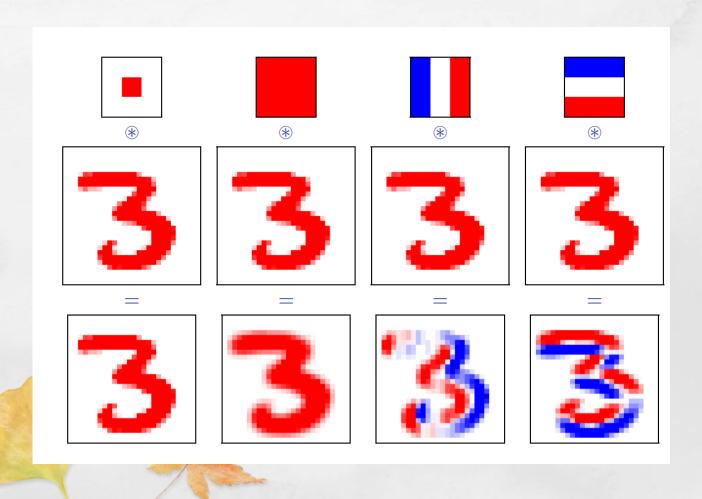
가중치가 크기 D× C× h× w인 커널을 포함하고, 크기 D 인 bias를 포함하는
 2d convolution의 입력 차원은 N×C×H×W
 이며 결과 차원은 N×D×(H-h+1)×(W-w+1) 임.

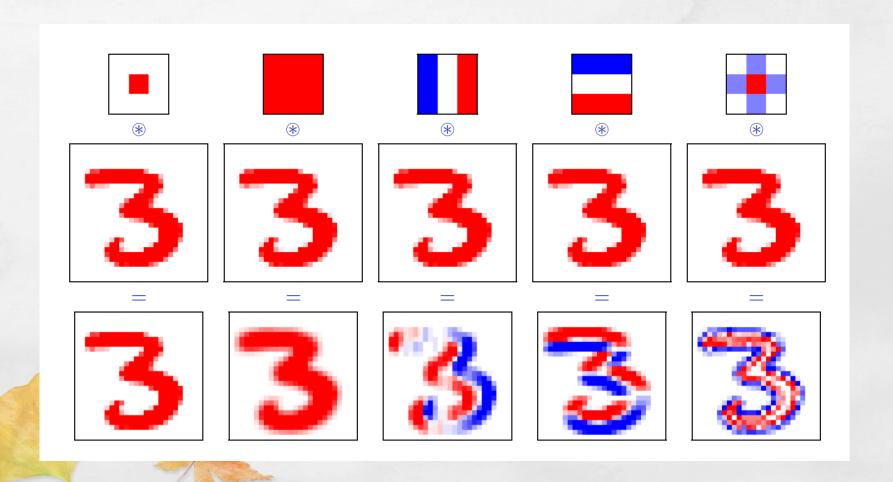
■ 유사하게 1d 와 3d convolutions을 구현함











```
class torch.nn.Conv2d(in_channels, out_channels, kernel_size, stride=1, padding=0, dilation=1, groups=1, bias=True)
```

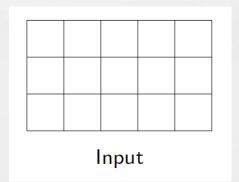
- convolution을 Module로 생성 시 kernel과 bias를 매개변수로 적절히 초기화 하면서 래핑 가능함.
- 커널 크기는 (h, w) 로 표현하거나, 상수 k 값으로 표현 할 수 있는데, 이는 (k, k) 임.

```
>>> f = nn.Conv2d(in_channels = 4, out_channels = 5, kernel_size = (2, 3))
>>> for n, p in f.named_parameters(): print(n, p.size())
...
weight torch.Size([5, 4, 2, 3])
bias torch.Size([5])
>>> x = torch.empty(117, 4, 10, 3).normal_()
>>> y = f(x)
>>> y.size()
torch.Size([117, 5, 9, 1])
```

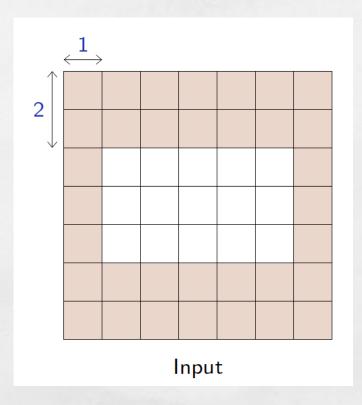
■ Convolutions은 두 가지 추가적인 표준 매개변수를 지님:

- padding 은 입력 주변에 0으로 채우는 frame을 의미하고,
- stride 신호를 가로 질러 kernel이 움직이는 step 크기를 지칭함.

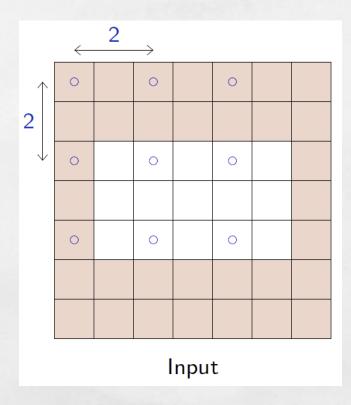
• Here with $C \times 3 \times 5$ as input

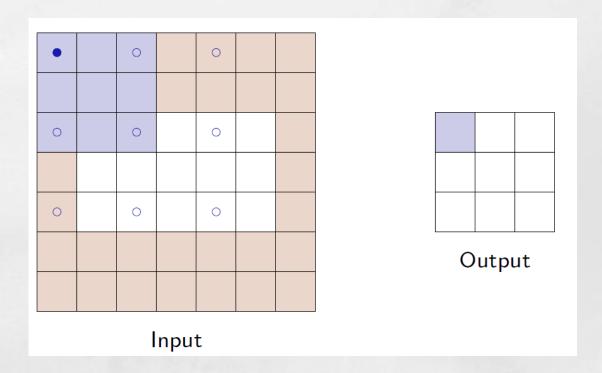


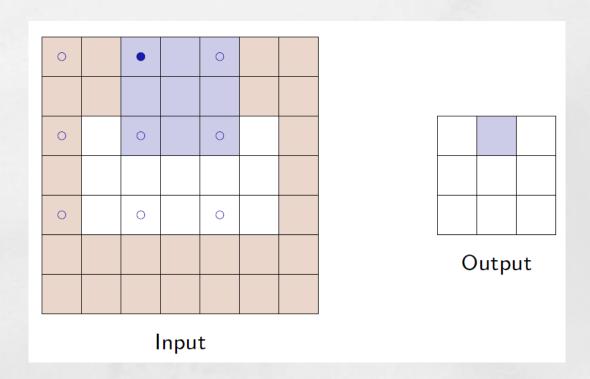
• Here with $C \times 3 \times 5$ as input, a padding of (2, 1)

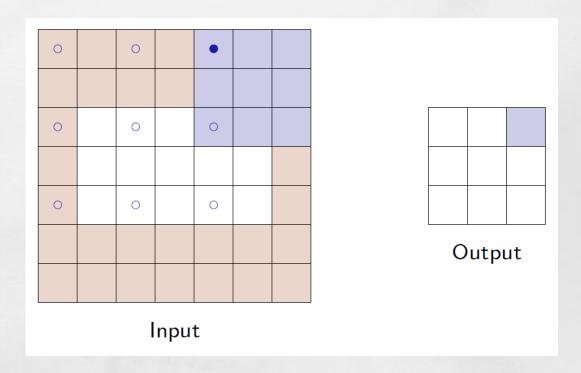


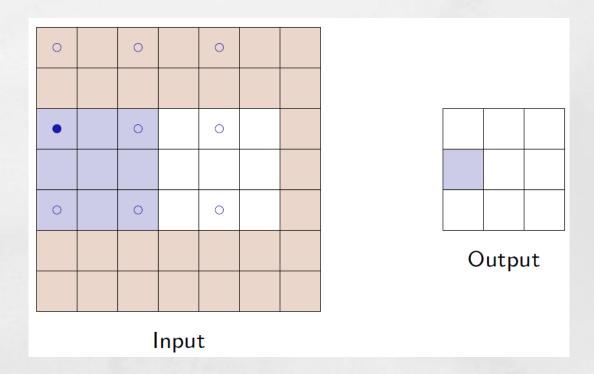
• Here with $C \times 3 \times 5$ as input, a padding of (2, 1), a stride of (2, 2)

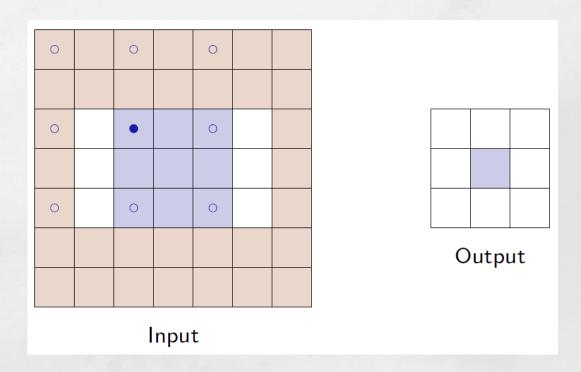


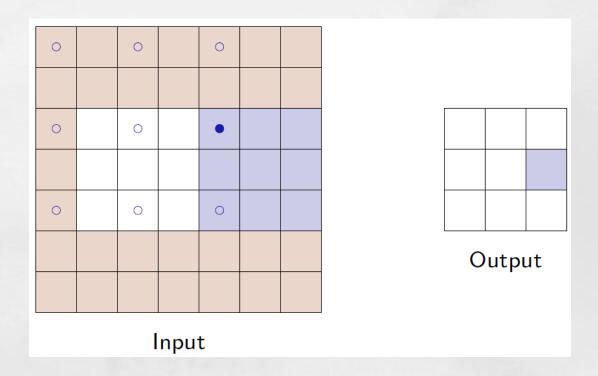


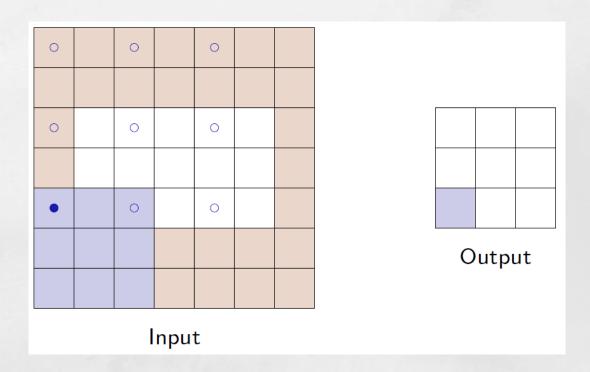


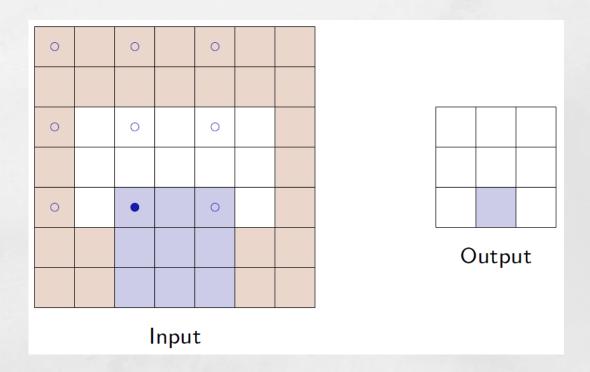


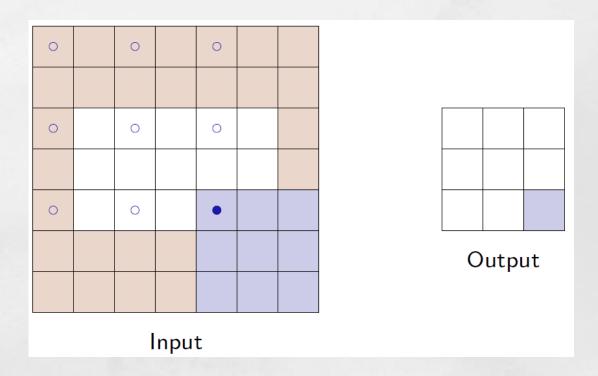


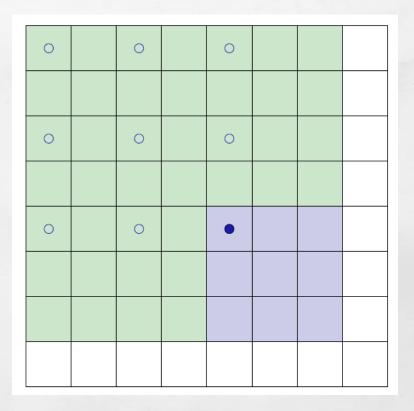






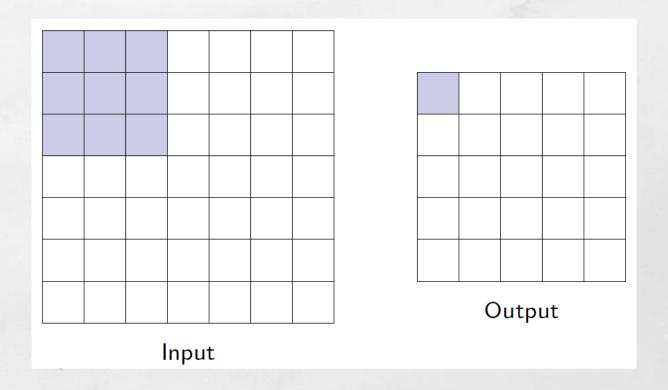


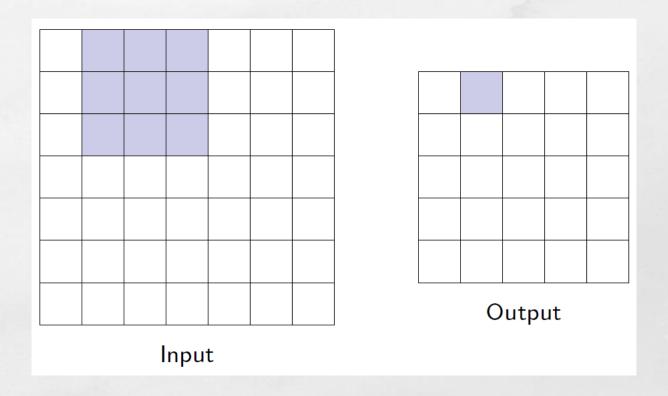


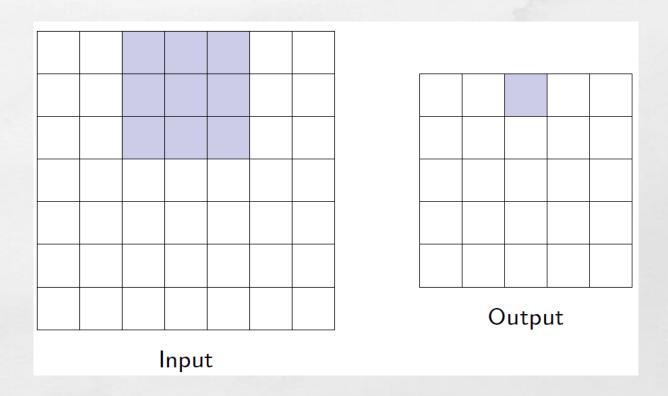


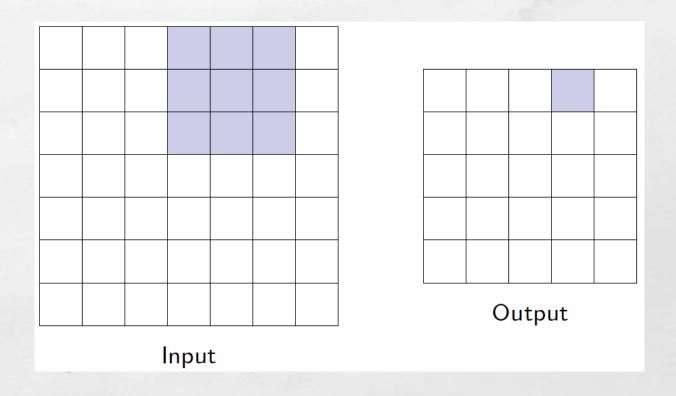
! stride가 1보다 큰 convolution은 입력 맵을 완전히 덮지 않을 수 있으므로, 일부 입력 값을 무시할 수 있음.

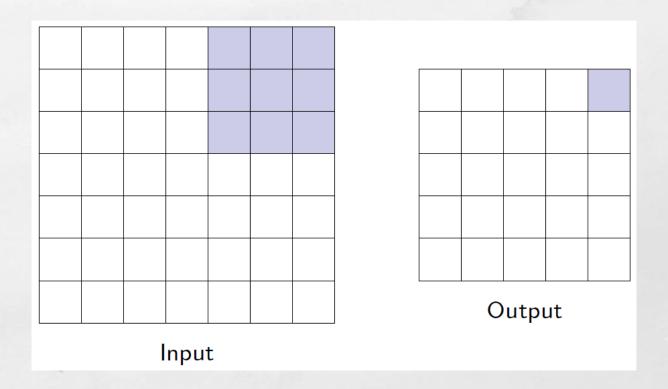
- Convolution 연산은 필터 지원을 확장을 조절하는 dilation이라는 표준 매개 변수를 허용함. (Yu and Koltun, 2015).
- 표준 convolution의 경우 1이지만 더 클 수 있음. 이 경우 결과 연산은 규칙적으로 희소 화 된 필터가 있는 convolution으로 구상 될 수 있음.
- 이 개념은 신호 처리에서 비롯됨. 여기서 알고리즘은 trous라고 하며, 따라서용어는 때때로 "convolution a trous"로 사용됨.

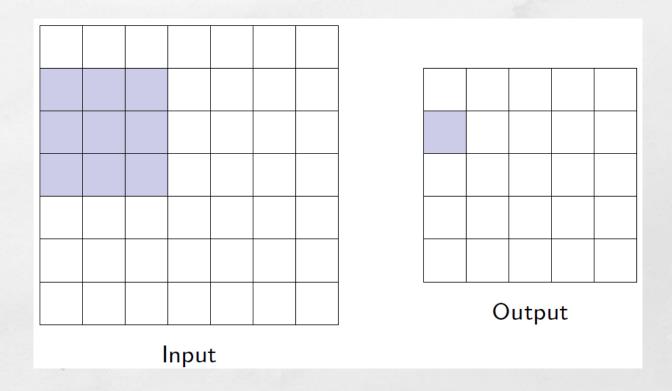


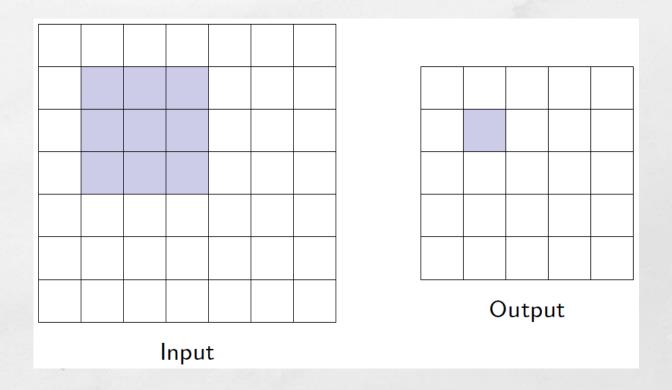


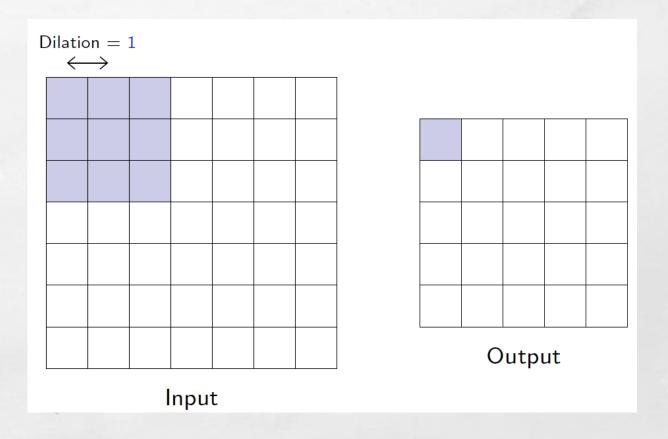


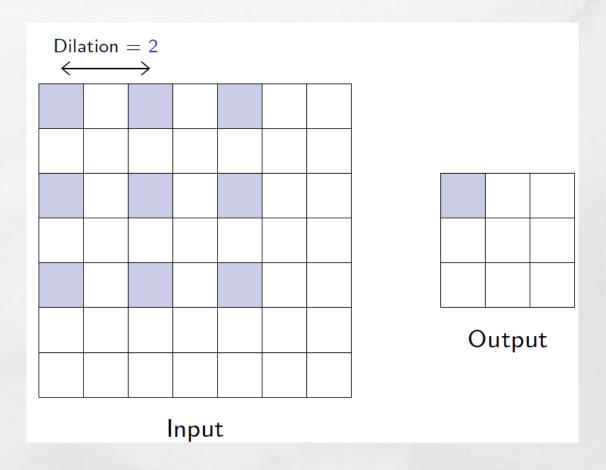


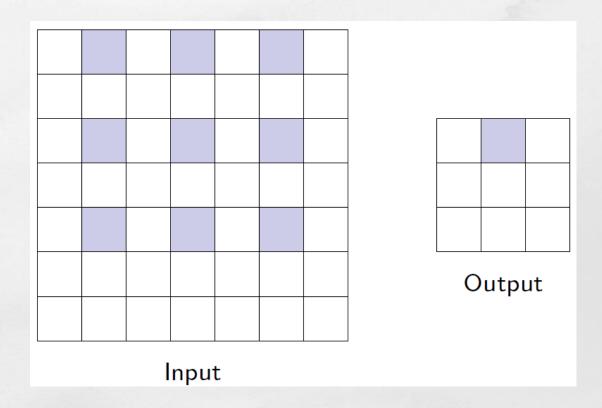


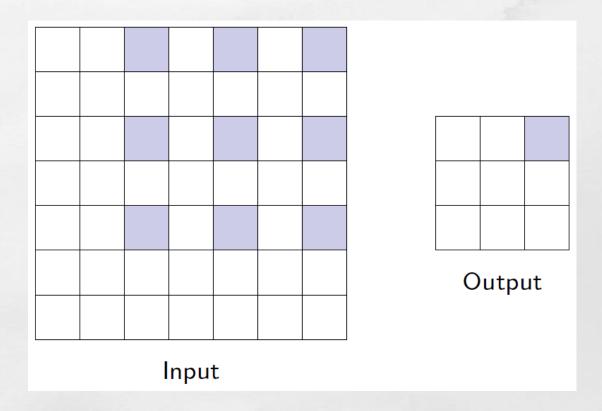


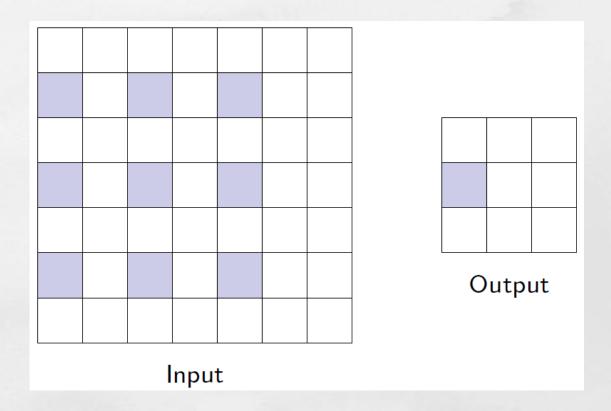


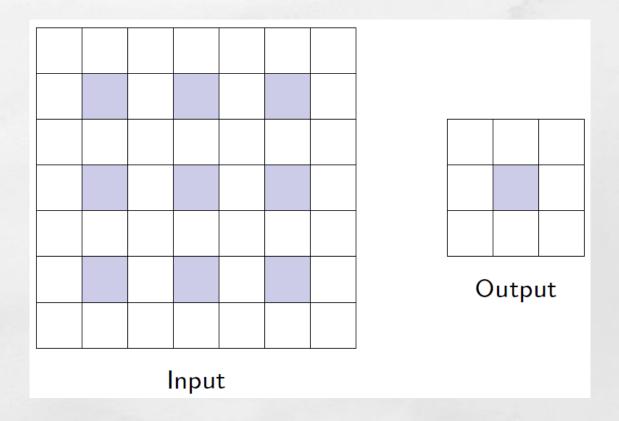


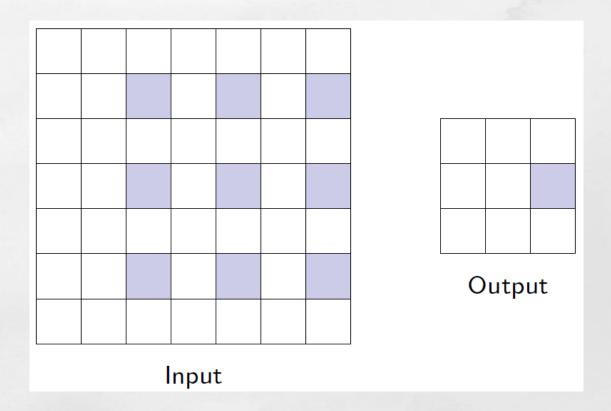


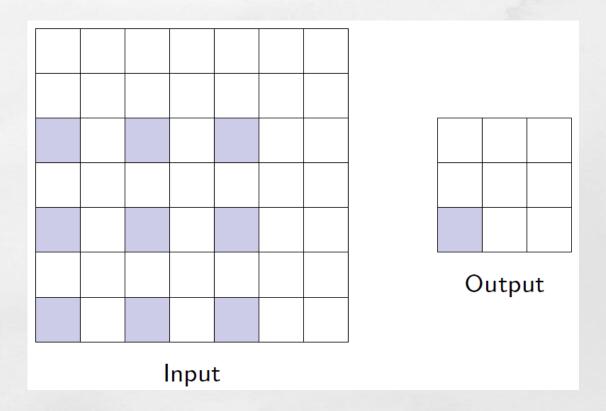


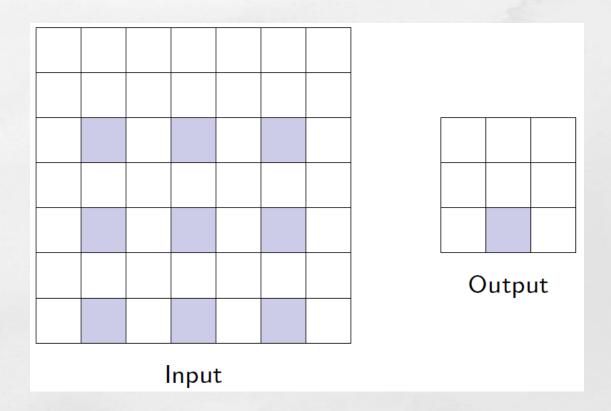


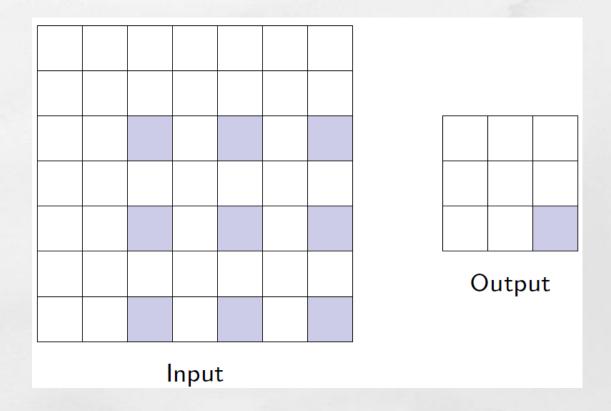












- 크기가 *k* 이고 dilation *d* A인 1d kernel이 있는 convolution은 0이 아닌 계수가 *k* 개인 필터 크기가 1 + (k-1)d 인 convolution으로 해석 될 수 있음.
- k = 3 이고 d = 4인 경우, 입력 map과 출력 map의 크기 차이는 1 + (3 - 1)4 - 1 = 8

```
In [63]: 1 \times = torch.empty(1, 1, 20, 30).normal_()
           2 \mid I = nn.Conv2d(1, 1, kernel_size=3, dilation=4)
           3 | I(x).size()
```

Out[63]: torch.Size([1, 1, 12, 22])

- dilation이 1보다 크면 매개 변수의 수를 늘리지 않고 단위의 receptive field 크기가 증가함.
- stride 또는 dilation이 1보다 큰 Convolutions는 마지막 classification decision에서 activation map 크기를 줄임.
- 그러한 네트워크의 단순성이 지니는 장점은:
 - 비선형 연산이 활성 함수에서만 이뤄진다는 점과,
 - 하나의 결과를 만드는 여러 활성함수를 결합하는 연산이 단지 선형 계층에서 만 이뤄진다는 점임.

- 이제 처음부터 첫 번째 convolutional network를 구축하는 데 필요한 브릭이 있음. 마지막 기술 포인트는 계층들(layer) 사이의 Tensor 모양임.
- convolutional layers 와 pooling layers는 모두 샘플의 입력을 배치로 사용하며 각 layer는 그 자체가 크기 $C \times H \times W$ 의 3D 텐서임.
- 출력은 같은 구조를 지니며, tensor들은 마지막 완전 연결 계층(fully connected layer)로 전달되기 전에 tensor형태가 변경되어 야 함.

Input sizes / operations	Nb. parameters	Nb. products
1 × 28 × 28		

Input sizes / operations	Nb. parameters	Nb. products
1 × 28 × 28		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5) $32 \times 24 \times 24$	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
F.max_pool2d(., kernel_size=3)	0	0
32 × 8 × 8		
F.relu(.)	0	0
$32 \times 8 \times 8$		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		

Input sizes / operations	Nb. parameters	Nb. products
1×28×28		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		

Input sizes / operations	Nb. parameters	Nb. products
1×28×28	·	
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		
x.view(-1, 256)	0	0
256		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
32 × 8 × 8		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		
x.view(-1, 256)	0	0
256		
nn.Linear(256, 200)	$200 \times (256 + 1) = 51,400$	$200 \times 256 = 51,200$
200		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		
x.view(-1, 256)	0	0
256		
nn.Linear(256, 200)	$200 \times (256 + 1) = 51,400$	$200 \times 256 = 51,200$
200		
F.relu(.)	0	0
200		

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		
x.view(-1, 256)	0	0
256		
nn.Linear(256, 200)	$200 \times (256 + 1) = 51,400$	$200 \times 256 = 51,200$
200		
F.relu(.)	0	0
200		
nn.Linear(200, 10)	$10 \times (200 + 1) = 2,010$	$10 \times 200 = 2,000$
10		

A classical LeNet-like model could be:

Input sizes / operations	Nb. parameters	Nb. products
$1 \times 28 \times 28$		
nn.Conv2d(1, 32, kernel_size=5)	$32 \times (5^2 + 1) = 832$	$32 \times 24^2 \times 5^2 = 460,800$
$32 \times 24 \times 24$		
<pre>F.max_pool2d(., kernel_size=3)</pre>	0	0
$32 \times 8 \times 8$		
F.relu(.)	0	0
$32 \times 8 \times 8$		
nn.Conv2d(32, 64, kernel_size=5)	$64 \times (32 \times 5^2 + 1) = 51,264$	$32 \times 64 \times 4^2 \times 5^2 = 819,200$
$64 \times 4 \times 4$		
<pre>F.max_pool2d(., kernel_size=2)</pre>	0	0
$64 \times 2 \times 2$		
F.relu(.)	0	0
$64 \times 2 \times 2$		
x.view(-1, 256)	0	0
256		
nn.Linear(256, 200)	$200 \times (256 + 1) = 51,400$	$200 \times 256 = 51,200$
200		
F.relu(.)	0	0
200		
nn.Linear(200, 10)	$10 \times (200 + 1) = 2,010$	$10 \times 200 = 2,000$
10		

• Total 105,506 parameters and 1,333,200 products for the forward pass.

- PyTorch 단순 architecture를 만들 수 있도록 sequential container module인 torch.nn.Sequential 지원함.
- 예를 들어, 입력이 10차원이고 출력이 2차원인 MLP 에 대해, ReLU 활성 함수와 100차원과 50차원의 두 은닉 계층은 다음과 같이 표현 가능함:

```
model = nn.Sequential(
nn.Linear(10, 100), nn.ReLU(),
nn.Linear(100, 50), nn.ReLU(),
nn.Linear(50, 2)
);
```

! 그러나, 산업계에 실제 응용되는 모델의 연산 복잡도를 고려할 때, 가장 좋은 접근 방법은 torch.nn. Module 의 sub-class를 구성하는 것임

■ Module 생성을 위해서는 base class를 상속 후, constructor __init__(self, ...) 과 the forward pass forward(self, x) 을 구현 해야 함.

```
In [68]:
             class Net(nn.Module):
                 def __init__(self):
                      super(Net, self).__init__()
                      self.conv1 = nn.Conv2d(1, 32, kernel_size=5)
                      self.conv2 = nn.Conv2d(32, 64, kernel size=5)
                      self.fc1 = nn.Linear(256, 200)
           6
                      self.fc2 = nn.Linear(200, 10)
                 def forward(self. x):
          10
                      x = F.relu(F.max_pool2d(self.conv1(x), kernel_size=3, stride=3))
                      x = F.relu(F.max_pool2d(self.conv2(x), kernel_size=2, stride=2))
                      x = x.view(-1.256)
                     x = F.relu(self.fc1(x))
          13
          14
                     x = self.fc2(x)
          15
                     return x
```

- torch.nn.Module 로 부터 상속을 함으로써 superclass에 구현된 많은 mechanism을 상속받게 됨.
- 먼저, (...) 연산자는 forward(...) 메서드 호출을 통해 재 정의되고, 추가 연산들을 실행함. The forward pass 는 이 연산자를 통해서 실행 되어야 하므로 직접 forward 호출하지 않도록 한다.
- 앞서 정의한 Net 클래스에 대해 우리는 단지 다음과 같이 정의 가능함

■ 또한 클래스 속성으로 더해진 모든 매개변수(Parameters)들은 Module.parameters()를 통해 확인 가능 함.

```
In [68]:
             class Net(nn.Module):
                 def __init__(self):
                     super(Net, self).__init__()
                     self.conv1 = nn.Conv2d(1, 32, kernel size=5)
                     self.conv2 = nn.Conv2d(32, 64, kernel size=5)
                     self.fc1 = nn.Linear(256, 200)
                     self.fc2 = nn.Linear(200.10)
                 def forward(self, x):
                    x = F.relu(F.max_pool2d(self.conv1(x), kernel_size=3, stride=3))
                    x = F.relu(F.max_pool2d(self.conv2(x), kernel_size=2, stride=2))
                    x = x.view(-1, 256)
                    x = F.relu(self.fc1(x))
                    x = self.fc2(x)
         14
                     return x
                                                                           1 for k in model.parameters():
                                                               In [70]:
                                                                                   print(k.size())
In [69]:
         1 model = Net()
          2 | input = torch.empty(12, 1, 28, 28).normal_()
                                                                          torch.Size([32, 1, 5, 5])
          3 | output = model(input)
                                                                          torch.Size([32])
          4 print(output.size())
                                                                          torch.Size([64, 32, 5, 5])
         torch.Size([12, 10])
                                                                          torch.Size([64])
                                                                          torch.Size([200, 256])
                                                                          torch.Size([200])
          1 for k in model.parameters():
                 print(k.size())
                                                                          torch.Size([10, 200])
                                                                          torch.Size([10])
```

! dictionaries 혹은 행렬에 더해진 매개변수는 볼 수 없음

```
class Buggy(nn.Module):
    def __init__(self):
        super(Buggy, self).__init__()
        self.com|v = nn.Conv2d(1, 32, kernel_size=5)
        self.param = Parameter(torch.zeros(123, 456))
        self.other_stuff = [ nn.Linear(543, 21) ]

model = Buggy()

for k in model.parameters():
    print(k.size())
```



prints

```
torch.Size([123, 456])
torch.Size([32, 1, 5, 5])
torch.Size([32])
```

! torch.nn.ModuleList는 모듈들을 더하는 단순 옵션으로 PyTorch 기계(?)에 의해 다루는 module들 list임.

```
class AnotherNotBuggy(nn.Module):
   def __init__(self):
        super(AnotherNotBuggy, self).__init__()
        self.conv = nn.Conv2d(1, 32, kernel_size=5)
        self.param = Parameter(torch.zeros(123, 456))
        self.other_stuff = nn.ModuleList()
        self.other_stuff.append(nn.Linear(543, 21))
model = AnotherNotBuggy()
                                   prints
for k in model.parameters():
    print(k.size())
                                   torch.Size([123, 456])
                                   torch.Size([32, 1, 5, 5])
                                   torch.Size([32])
                                   torch.Size([21, 543])
                                   torch.Size([21])
```

- autograd 에 호환되는 연산자들을 이용하면, back ward pass는 자동으로 구현됨.
- 이는 경사 하강 법(gradient descent)으로 매개변수들을 최적화하는 데 있어 매우 중요함.



7) Pytorch 실습 on Google CoLab

https://colab.research.google.com/github/pytorch/tutorials/blob/gh-pages/_downloads/5ddab57bb7482fbcc76722617dd47324/nn_tutorial.ipynb

